

Input Image



Image
Encoder

I_1

$I_1 \cdot T_1$ $I_1 \cdot T_2$... $I_1 \cdot T_4$ $I_1 \cdot T_N$

cosine similarity

argmax

Spider Man

Wolverine

Deadpool

⋮

Spider Man

Hatsune Miku

Labels

Text
Encoder

T_1

T_2

...

T_4

T_N